



**UNIVERSITAT
ROVIRA I VIRGILI**

**Desarrollo de un pipeline para el análisis de datos de
espectrometría de masas por imágenes para muestras de cáncer
de vejiga urinaria.**

Adrián Manzano Martínez

TRABAJO FINAL DE GRADO BIOTECNOLOGÍA

Tutor académico: Dr. Santiago García Vallvé (santi.garcia-vallve@urv.cat), profesor del grado en Biotecnología, dpto. de Bioquímica y Biotecnología.

En cooperación con Mil@b de la Universidad Rovira i Virgili (URV)

Supervisor: Dr. Óscar Yanes Torrado (oscar.yanes@urv.cat), profesor de la doble titulación ingeniería biomédica e Ingeniería de Sistemas y Servicios comunicativos, depto. Ingeniería Electrónica, Eléctrica y Automática.

Fecha de convocatoria, junio 2025.

Yo, Adrián Manzano Martínez, con DNI 09108557M, soy conocedor de la guía de prevención del plagio de la URV. Prevención y tratamiento del plagio en la docencia: guía para estudiantes (aprobada en julio 2017) (<http://www.urv.cat/ca/vidacampus/serveis/crai/que-us-oferim/formaciocompetencies-nuclears/plagi/>) y afirmo que este TFG no constituye ninguna de las conductas consideradas como plagio por la URV.

Tarragona, 2 de junio de 2025

A handwritten signature in black ink, appearing to read 'Adrián', with a stylized flourish extending from the end.

Agradecimientos:

Me gustaría mostrar mi más sentido agradecimiento:

“A mi tutor profesional, el Dr. Óscar Yanes Torrado, por darme la oportunidad de colaborar con el grupo Mil@b”

“A mi tutor académico, el Dr. Santiago García Vallvé por los innumerables correos electrónicos y las innumerables preguntas sobre el desarrollo de este trabajo”

“A Nadia Moltó Llisó, por su ayuda, paciencia y disposición durante el desarrollo de este TFG. Gracias por tu paciencia en la enseñanza y ayudarme al defender este proyecto”

“A mis padres y a mi hermana, que me han enseñado todo lo que se. Siempre han creído en mí y a quienes les debo todo. Gracias por haberlo dado todo por mí, vuestro apoyo y amor incondicional. Todo lo que soy es gracias a vosotros. Os quiero”

“A mis abuelas, Nélida y Julia por estar orgullosas de mí y apoyarme durante todo el grado y la experiencia de haber estudiado lejos de mi hogar”

“A mis tíos, Juanjo, Estela, Ana y Pepe por haber aguantado mis momentos más duros y haberme dado comprensión, amor y motivación para seguir siempre adelante”

“A Tarragona por darme la oportunidad de desarrollarme tanto a nivel personal como académico. Gracias por hacerme quien soy”

“A mis amigos por enseñarme el significado de la palabra REAL, la cual ha guiado mi camino en Tarragona”

ÍNDICE:

1. Resúmen y palabras clave:	1
2. Datos del Centro:	2
3. Introducción:	3
3.1 Introducción general a la Espectrometría de Masas por Imágenes:	3
3.2 Espectrometría de Masas con Desorción/Ionización por Láser Asistida por Matriz (MALDI-MSI):	3
3.3 Aplicación de MALDI-MSI en el Cáncer de Vejiga:	5
3.4 Corregistro de Imágenes Multimodales y Relevancia Clínica:	6
3.5 Desafíos Actuales en MALDI-MSI:	7
4. Hipótesis y Objetivos:	8
5. Metodología:	9
5.1 Conjunto de Datos:	10
5.2. Preprocesamiento de los datos en crudo con el paquete de R, r-MSI2:	11
5.3. Tratamiento de la pks mediante las normalizaciones TIC, RMS y MAX:	12
5.4. Reducción de la dimensionalidad de los datos con PCA, t-SNE y UMAP:	13
5.5. Agrupamiento de datos mediante algoritmos de clusterización (K-Means, DBSCAN y HClust):	17
5.6. Evaluaciones de las diferentes combinaciones descritas e identificación de un ion de la zona tumoral y corregistro del mismo:	20
6. Resultados y Discusión:	21
6.1 Evaluaciones visuales según la comparativa con la imagen histopatológica:	21
6.2 Evaluación según el coste computacional:	27
6.3 Evaluación según la media de Silhouette:	28
6.4 Filtrado de m/z con interés biológico:	30
6.5. Anotación en HMDB y corregistro:	32
6.6. Comparaciones con otros estudios, limitaciones y perspectivas futuras:	34
7. Conclusiones:	36
8. Autoevaluación:	37
9. Bibliografía y Webgrafía:	38
ANEXO I: Tabla resumen de los métodos de reducción de la dimensionalidad aplicados en el estudio:	42
ANEXO II: Tabla resumen de los algoritmos de clusterización aplicados en el estudio:	43

1. Resumen y palabras clave:

La espectrometría de masas por imágenes (MSI) permite obtener información espacial sobre la distribución de metabolitos, lípidos y proteínas en tejidos, siendo especialmente útil en patologías complejas como el cáncer de vejiga urinaria. No obstante, su análisis bioinformático presenta retos como la alta dimensionalidad, la falta de estandarización y automatización en el tratamiento de datos, lo que evidencia la necesidad de desarrollar y evaluar un protocolo automático para el tratamiento de los datos. Por ello, este estudio ha evaluado y desarrollado un pipeline bioinformático para la segmentación automática de una región tumor y una estromal en una imagen MSI de una muestra de cáncer vesical urinario. Este pipeline ha sido diseñado a partir de la evaluación de 48 combinaciones de métodos de normalización (TIC, RMS y MAX), reducción de la dimensionalidad (PCA, t-SNE, UMAP) y algoritmos de clusterización (K-Means, DBSCAN, HClust). Su evaluación combinó análisis visual de las segmentaciones y métricas cuantitativas como la media de Silhouette y el coste computacional. La combinación que ha demostrado ser más eficiente como posible pipeline ha resultado ser la normalización por MAX, junto con la reducción por UMAP y la segmentación con K-Means. Además, se ha validado biológicamente su utilidad mediante la caracterización de un ión correspondiente a un lípido PE-NMe₂, implicado en la síntesis de fosfatidilcolina y previamente asociado a otras neoplasias. El correregistro de este ión ha evidenciado una clara correspondencia con la región tumoral, lo que abre la posibilidad de estudiarlo como un potencial biomarcador de esta patología.

Palabras clave: *Espectrometría de masas por imágenes (MSI), Cáncer de vejiga urinaria, Segmentación automática de tejidos, Pipeline bioinformático, Reducción de dimensionalidad, Algoritmos de clusterización, Normalización de datos), Media de Silhouette, Correregistro histológico, PE-NMe₂.*

2.Datos del Centro:

Mil@b (“The Metabolomis Interdisciplinary Laboratory”) se trata de un grupo de investigación interdisciplinar de la URV. Está codirigido por la Dra. María Vinaixa y el Dr. Óscar Yanes y presenta 16 científicos incluyendo estudiantes y profesores. Los miembros del grupo están adscritos al Departamento de Ingeniería Eléctrica, Electrónica y Automática de la URV (DEEEiA URV) y al Instituto de Investigación Sanitaria Pere Virgili (IISPV).

Este grupo de la URV está financiado por la Generalitat de Catalunya (2021 SGR 00842) y con diferentes proyectos Internacionales financiados por la Comisión Europea y Nacionales financiados por el Ministerio de Ciencia e Innovación. Además, es importante comentar la contribución de Mil@b en la Plataforma de Metabolómica, que se trata de una instalación de investigación conjunta CIBERDEM/IISPV-URV y que fue creada en 2007.

En cuanto al enfoque de Mil@b se basa en aplicar principios de ingeniería y tecnología para comprender nuestro metaboloma y así poder avanzar en la medicina de precisión y personalizada. Las principales líneas de investigación se basan en la Metabolómica computacional, la Histología molecular sin etiquetas y la Metabolómica clínica.

Por otro lado, Mil@b ofrece herramientas computacionales desarrolladas internamente para la comunidad científica en el campo de la metabolómica como lo es el paquete de R denominado r-MSI2 para el preprocesamiento de datos de espectrometría de masas por imagen (MSI).

Mil@b utiliza las instalaciones del Servei de Recursos Científics i Tècnics (SRCiT) en la URV. En estas instalaciones dispone de una amplia gama de equipamientos para metabolómica en este servicio de la URV. El equipamiento usado durante las prácticas fue el MS Orbitrap ID-X con una fuente de ionización para la técnica MALDI acoplada para realizar la técnica de MSI anteriormente mencionada, pero cuenta con otros equipos para la identificación de metabolitos como pueden ser equipos de RMN.

3. Introducción:

3.1 Introducción general a la Espectrometría de Masas por Imágenes:

La Espectrometría de masas por imágenes (MSI, “Mass Spectrometry Imaging”) se trata de una técnica analítica, que permite obtener imágenes iónicas a partir de tejidos biológicos. Esta técnica se ha desarrollado como respuesta a la necesidad de mejorar la comprensión de diferentes procesos biológicos y patológicos, mediante la visualización espacial de los metabolitos, proteínas y lípidos en cortes histológicos. Desde sus primeras publicaciones en la década de 1980 (Levi-Setti et al., 1985) (Legeais et al., 1989), MSI ha revolucionado el campo de la investigación al permitir la evaluación de la distribución de las moléculas dentro en los tejidos biológicos con una alta resolución espacial. Al inicio de la historia, la modalidad de MSI mayormente empleada se basaba en la espectrometría de masas de iones secundarios (SIMS-MSI) debido a su alta resolución espacial (Chabala et al., 1988). Sin embargo, esta modalidad presentaba un gran inconveniente relacionado con la fragmentación excesiva de las moléculas a analizar (Parees et al., 1998). Por esta razón, entre las diferentes modalidades actuales de MSI, una de las más empleadas actualmente es la espectrometría de masas con desorción/ionización por láser asistida por matriz (MALDI-MSI) (Tuck et al., 2022).

3.2 Espectrometría de Masas con Desorción/Ionización por Láser Asistida por Matriz (MALDI-MSI):

MALDI-MSI se ha consolidado como una herramienta clave en la investigación biomédica. La capacidad de MALDI-MSI para mapear la distribución molecular en cortes histológicos ha promovido que sea una de las técnicas clave a la hora de abordar la búsqueda de potenciales biomarcadores en secciones tisulares para análisis patológicos, ya que permite conocer su distribución e implicación metabólica, potenciando el entendimiento sobre la patología de interés. Un ejemplo de biomarcador caracterizado con MALDI-MSI puede ser la vimentina, esta molécula presenta una sobreexpresión en el cáncer de mama triple negativo (Gonçalves et al., 2023).

El principio fundamental de MALDI-MSI se basa en la ionización de moléculas presentes en un corte histológico de tejido. El proceso comienza con la preparación del tejido, que se congela y se corta en secciones delgadas mediante un crióstato. Estos cortes se colocan sobre un portaobjetos y luego se les aplica una matriz química utilizando un evaporador térmico al vacío. A este proceso se le denomina deposición física de vapor (PVD) (Gemperline et al., 2014). La matriz desempeña un papel clave, ya que absorbe la energía del láser y facilita la posterior

ionización. En la figura 1 se puede observar este papel que tienen las matrices en el proceso de ionización. En relación con las matrices, es importante comentar que existen diferentes tipos de matrices empleadas en MALDI y que pueden tener efectos importantes en los resultados. Un ejemplo de matriz MALDI ampliamente utilizada es el DHB (ácido 2,5-dihidroxibenzoico) (Tressler et al., 2021), que gracias a su estructura aromática absorbe mejor la energía, lo que mejora la ionización del analito y permite obtener espectros más claros y definidos.




Figura 1: Representación esquemática de cómo la matriz facilita el proceso de ionización y de formación de iones gaseosos que son dirigidos al MS. Fuente: Figura 20.2.7 (LibreTexts, 2023).

En MALDI, la ionización se lleva a cabo con un láser, que incide sobre la muestra punto por punto. Este láser excita la matriz, que a su vez transfiere la energía a los analitos presentes en la muestra, provocando así su desorción y posterior ionización. Como resultado, se generan iones gaseosos que son dirigidos al espectrómetro de masas (MS) mediante un sistema de lentes. El MS genera un perfil de masa-carga (m/z) para cada uno de los iones gaseosos detectados, permitiendo la construcción de un espectro con diferentes m/z y sus respectivas intensidades en cada punto del tejido. Este proceso lleva a la generación de imágenes en las que cada píxel, definido por unas coordenadas X e Y, contiene un espectro con cada uno de los m/z y sus respectivas intensidades. En la figura 2 se puede observar todo el proceso, desde la ionización de la muestra hasta la generación de imágenes. Además, estas imágenes generadas tras el paso por el MS pueden ser representadas por colores (“Heat-Maps”) en función de la intensidad de él ion seleccionado para la representación.




Figura 2: Representación esquemática del “workflow” de MALDI-MSI. Se muestra la disposición de la matriz, la ionización mediante láser, la detección y la generación de espectros de masas, donde cada espectro corresponde a un píxel de la muestra, y la posterior generación de imágenes para iones específicos. Fuente: Figura 5 (Ren et al., 2018).

3.3 Aplicación de MALDI-MSI en el Cáncer de Vejiga:

La técnica MALDI-MSI se ha consolidado como una herramienta con un gran potencial en oncología (Wallace et al., 2024), donde es posible estudiar la heterogeneidad tumoral y para la identificación de posibles biomarcadores para el diagnóstico y pronóstico del cáncer.

El cáncer de vejiga urinaria o cáncer vesical urinario es uno de los tipos de neoplasias más comunes a nivel mundial, llegando a ser diagnosticado en 614,298 personas en todo el mundo en 2022, lo que supone un aumento del 7,1% respecto a 2020 (World Bladder Cancer Patient Coalition, 2022). Si se detecta a tiempo, suele ser una enfermedad tratable con una elevada esperanza de supervivencia. Sin embargo, si la detección no es temprana, esta enfermedad puede dar lugar a metástasis a ganglios linfáticos, huesos, pulmones e hígado. Esta metástasis se asocia a una esperanza de vida de unos 15 meses. Las células epiteliales de la vejiga (Uroteliales) son las células primarias de origen del cáncer de vejiga. De hecho, el 95% de los pacientes que presentan un cáncer vesical urotelial es debido a estas células epiteliales y el 5% restante son debidos a otros tipos celulares de la vejiga como las células escamosas o las células glandulares. El tabaco es la causa principal de este tipo de neoplasia, ya que esta capa epitelial está expuesta a diferentes metabolitos cancerígenos del tabaco que son eliminados a través de la orina. Además, en los últimos años, la incidencia global del cáncer de vejiga ha aumentado, siendo especialmente prevalente en hombres europeos mayores de 55 años (Dyrskjøl et al., 2023).

Aunque técnicas como la cistoscopia y la citología urinaria han mejorado el diagnóstico, la clasificación molecular precisa de las neoplasias vesicales sigue siendo una tarea compleja. En este contexto, entender los cambios metabólicos que ocurren en el cáncer de vejiga es esencial para avanzar en la identificación de biomarcadores y el desarrollo de tratamientos más efectivos.

En este contexto, MALDI-MSI ofrece una ventaja significativa al permitir el análisis de la distribución de metabolitos en distintas regiones del tejido. Las imágenes generadas por MALDI-MSI permiten visualizar y mapear metabolitos asociados con la presencia y progresión tumoral. Este proceso facilita la caracterización de biomarcadores relevantes para el diagnóstico y pronóstico del cáncer de vejiga, y abre nuevas posibilidades para personalizar los tratamientos.

3.4 Corregistro de Imágenes Multimodales y Relevancia Clínica:

El proceso de corregistro de imágenes multimodales (Ollen-Bittle et al., 2024) permite la correlación de las imágenes de MSI con imágenes histopatológicas de secciones de tejido, facilitando la comprensión de la distribución de los iones en las diferentes áreas del tejido. De esta forma, es posible identificar metabolitos y observar su distribución, lo que permite comprender mejor su posible papel en el desarrollo y progresión de patologías.

En la figura 3 se observa un ejemplo de resultado de un corregistro entre una imagen histológica de un ratón con la imagen MSI. Estas imágenes histológicas pueden ser de distintos tipos, como las de tinción Hematoxilina y Eosina (H&E), que permiten observar la estructura celular y tisular a través de la tinción de componentes celulares, o las imágenes microscópicas obtenidas mediante técnicas avanzadas de microscopía, como la microscopía de fluorescencia o la microscopía electrónica. Este corregistro es fundamental para integrar la información metabólica de las imágenes de MSI con la información anatómica y celular proporcionada por las imágenes histológicas. De este modo, se facilita una evaluación más precisa e interpretativa para los médicos y patólogos, permitiendo correlacionar las alteraciones metabólicas con la morfología y la estructura del tejido. Por tanto, el corregistro puede resultar esencial para un correcto diagnóstico y pronóstico, especialmente en enfermedades como el cáncer.




Figura 3: Corregistro multimodal de una imagen de MSI con una imagen histológica de una vejiga urinaria de ratón. Se muestra la imagen histológica (“Optical Image”) en rojo y la imagen MSI del ion seleccionado en verde (“Mass spec. Image”). La comparación entre la superposición inicial (“Overlay before coregistration”) y el resultado final del corregistro (“Overlay after coregistration”) demuestra la alineación espacial lograda. Este análisis permite correlacionar la distribución molecular del analito seleccionado con la estructura histológica del tejido. Fuente: Figura 9 [Memoria de Prácticas de Adrián Manzano Martínez].

3.5 Desafíos Actuales en MALDI-MSI:

A pesar de sus grandes avances, MSI sigue siendo una técnica en aras de investigación con varios desafíos que limitan su adopción generalizada. Uno de los principales problemas que enfrenta la técnica es la alta dimensionalidad de los datos (Pathirage et al., 2024). Por ejemplo, un conjunto de datos o “Dataset” de MALDI-MSI con alta resolución y varias imágenes puede llegar a ocupar 1 TB. Esta alta dimensionalidad hace que el análisis de los datos sea complejo y requiere herramientas bioinformáticas avanzadas para su reducción y visualización.

Además, la técnica enfrenta desafíos relacionados con la poca automatización en el análisis de datos (Hu & Laskin, 2022), lo que hace que el procesamiento de los resultados sea un proceso laborioso. Los pasos fundamentales como la normalización, la reducción de la dimensionalidad y la segmentación o clusterizado de los datos no están completamente estandarizados, generando inconsistencias en los resultados y dificultando la comparación entre diferentes estudios. Por ello, existe la necesidad de establecer un protocolo o pipeline para el análisis de datos en el que se reflejen métodos de normalización, reducción y clusterización óptimos. Siendo este pipeline automático y escalable a diferentes conjuntos de datos de alta dimensionalidad.

Otro reto importante es la dificultad del corregistro de imágenes de MSI con imágenes histológicas, debido a la variabilidad entre ambas modalidades de imágenes. Esto se debe a que provienen de cortes consecutivos y no de la misma sección exacta, haciendo compleja la superposición o corregistro de una imagen MSI y su correspondiente imagen histopatológica. Por esta razón, se han propuestos diferentes herramientas para facilitar el corregistro, como los paquetes de R MSIr o MSIreg (Lin et al., 2023) (Lakkimsetty et al., 2024). Sin embargo, este proceso sigue sin estar completamente resuelto, ya que generalmente requiere intervención manual y aún persisten importantes limitaciones en cuanto a la fidelidad morfológica entre ambas imágenes.

A pesar de estos desafíos, la MSI tiene un gran potencial en la investigación biomédica. El análisis bioinformático de los datos es esencial para transformar los resultados de MSI en información útil para médicos y patólogos. Por esta razón, este trabajo se centra en abordar algunos de estos problemas bioinformáticos y establecer un protocolo para el análisis y corregistro de un corte histológico de cáncer de vejiga urinaria humana.

4. Hipótesis y Objetivos:

El cáncer vesical urinario exhibe una gran heterogeneidad a nivel histológico y molecular (Hamidi et al., 2024), lo que dificulta mucho su tratamiento personalizado. En otros tipos de neoplasias, como el hepatocolangiocarcinoma combinado, estudios previos utilizando MALDI-MSI han demostrado ser útiles para segmentar las imágenes MSI en diferentes regiones tumorales mediante análisis bioinformáticos (Gigante et al., 2023). En dicho estudio, la segmentación permitió discernir regiones correspondientes a hepatocarcinoma y colangiocarcinoma, las cuales mostraron una buena correspondencia con la imagen histopatológica.

Partiendo de esta base, la hipótesis de este trabajo plantea que la aplicación del análisis bioinformático de imágenes MSI de un cáncer de vejiga urinario, puede permitir la identificación de una región tumoral y una estromática, que coincidan con la anotación histopatológica. El término de estroma tumoral es utilizado comúnmente en oncología y hace referencia al tejido de soporte (conjuntivo, vasos sanguíneos, etc.) de las células tumorales y que podría estar alterado por la presencia del tumor. Esta diferenciación de la región tumoral de la estromática podría manifestarse en variaciones en la distribución de metabolitos y lípidos, lo que podría contribuir a la posible detección de potenciales biomarcadores y entender su implicación metabólica en este tipo de neoplasia.

Para abordar esta hipótesis, se plantea un objetivo principal estrechamente relacionado con los desafíos anteriormente mencionados de MSI. Este se centrará en la evaluación e implementación de un pipeline o protocolo para la segmentación automatizada de imágenes de MSI. Para el desarrollo de este protocolo, se explorarán diferentes combinaciones de tratamientos estadísticos de normalización de los datos MSI con diferentes técnicas de reducción de la dimensionalidad y algoritmos de clusterización o segmentación de datos.

Adicionalmente a este objetivo, se llevará a cabo la identificación y caracterización de un m/z altamente representativo de la región tumoral mediante el uso de una base de datos metabolómica como HMDB (“Human Metabolome Database”). Asimismo, se realizará el correregistro de este ión en la imagen histopatológica para visualizar su distribución a nivel celular. De este modo, este objetivo adicional basado en la anotación de un m/z y correregistro del mismo permitirá validar biológicamente el pipeline desarrollado y abrirá la posibilidad de que este ión sea estudiado en futuros estudios como un potencial biomarcador de esta neoplasia.

5. Metodología:

El flujo de trabajo seguido en este estudio se resume en la Figura 4, y tiene como objetivo abordar la hipótesis planteada mediante el diseño de un pipeline bioinformático robusto y escalable para el análisis de datos de MSI. El proceso ha comenzado con el preprocesamiento de los datos en crudo procedentes del MS utilizando el paquete de R r-MSI2 (Ràfols et al., 2017), desarrollado por el grupo Mil@b, cuyo resultado ha sido una matriz de picos, “peak matrix” (pks). A partir de esta matriz, se han aplicado tres métodos de normalización, junto con una cuarta opción sin normalizar (TIC, RMS, MAX y no tratados). Posteriormente, se han evaluado 4 enfoques de reducción de dimensionalidad y uno sin reducción (PCA, t-SNE, UMAP y sin reducción). Finalmente, han sido aplicados tres algoritmos de clusterización o segmentación no supervisada de datos de la imagen de MSI (K-Means, DBSCAN y HClust).

En total, se han evaluado 48 combinaciones diferentes, resultantes de aplicar los cuatro enfoques de normalización, los cuatro enfoques de reducción de dimensionalidad y los tres algoritmos de clusterización ($4 \times 4 \times 3$). El objetivo de estas evaluaciones se ha basado en identificar la combinación de métodos que ofrezca una segmentación precisa del tejido en una región tumoral y una estromática, asegurando su correspondencia con la anotación histopatológica de referencia. Esta estrategia busca establecer un pipeline reproducible y escalable para el análisis y corregistro de imágenes MSI, cumpliendo con la hipótesis del estudio al permitir distinguir computacionalmente la región tumoral y estromática del tejido.




Figura 4: Flujo de trabajo del estudio dividido en 6 partes: 1- Conjunto de datos del MS o datos en crudo (“Raw Dataset”) procedentes del MS. 2- Preprocesamiento de los datos mediante el paquete de R r-MSI2. 3- Matriz resultante del preprocesamiento (pks). 4- Tratamiento de los datos mediante normalizaciones (TIC, RMS y MAX) junto con la pks sin normalizar. 5- Reducción de la dimensionalidad mediante diferentes técnicas (PCA, t-SNE y UMAP) junto con la no reducción. Las reducciones y la no reducción de los datos se han aplicado a cada una de las normalizaciones y a la pks. 6- Agrupamiento de los datos mediante diferentes algoritmos de clusterización (K-Means, DBSCAN y HClust), aplicados a cada una de las reducciones y las no reducciones. Fuente: [Elaboración propia].

5.1 Conjunto de Datos:

En este estudio, se ha utilizado un conjunto de datos de MSI procedentes de un corte histopatológico de cáncer de vejiga urinario humano. Las muestras provienen de un estudio cooperativo entre el Hospital Joan XXIII de Tarragona y el grupo de investigación Mil@b. La preparación de las muestras se centró en hacer una sección de 5 μ M con un criostato de un tejido neoplásico de vejiga. Esta sección ha sido montada en un portaobjetos con un 3% de carboximetilcelulosa (CMC) para el mantenimiento de la integridad del tejido. Además, se ha realizado una tinción de hematoxilina y eosina (H&E) para facilitar el diagnóstico y anotación de la región tumoral y estromática por parte del patólogo. Este tipo de tinciones usan dos colorantes: la hematoxilina tiñe los núcleos celulares y la eosina los citoplasmas. Tras el procesamiento de la muestra en el laboratorio, el patólogo anotó una sección de tejido tratado con H&E empleando el programa QuPath (Humphries et al., 2021) cuyo resultado se puede observar en la figura 5, junto con la misma imagen invertida y rotada para facilitar el posterior análisis bioinformático.




Figura 5: A) Imagen de la anotación patológica del corte histopatológico teñido con H&E del cáncer de vejiga urinario. B) Imagen invertida y rotada de la anotación patológica del corte histopatológico teñido con H&E del cáncer de vejiga urinario para facilitar el trabajo con R. Las líneas de color rojo corresponden a islotes neoplásicos de la región tumoral, mientras que las de color verde corresponden a subregiones de la región de estroma. Fuente: [Conjunto de datos de Mil@b y el Hospital Joan XXIII de Tarragona].

Finalmente, para el análisis MALDI-MSI se ha aplicado una matriz de oro nanoestructurado con el objetivo de mejorar la ionización MALDI, tal y como se comentó en la introducción. Para la deposición de la matriz, se ha empleado un sistema de deposición física de vapor (PVD) mediante el equipo ATC Orion 8-HV (AJA International). En cuanto al análisis por MALDI-MSI, se ha utilizado una fuente de ionización para la técnica MALDI de la marca Spectrograph y un MS del modelo Orbitrap Exploris con una resolución de 60 000 @m/z 200 en modo positivo. Esta resolución es adecuada para la detección de lípidos, N-glicanos y péptidos. Tras

el paso por el MS, se obtuvo un conjunto de archivos con los datos en crudo, es decir datos del MS sin procesar. Estos archivos consisten en un archivo de metadatos (.IMZML) y un archivo de datos binario (.IBD). Estos archivos trabajan en conjunto, el archivo (.IMZML) contiene detalles experimentales y las posiciones (x,y) de cada píxel en la imagen, mientras que el archivo (.IBD) presenta los diferentes m/z e intensidades de los mismos en cada punto del corte. En resumen, estos archivos en conjunto contienen toda la información con respecto a las posiciones de los m/z y sus intensidades en el corte histopatológico para la generación de las imágenes MSI.

5.2. Preprocesamiento de los datos en crudo con el paquete de R, r-MSI2:

Como ya se comentó anteriormente, cada píxel de la imagen tiene asociado un espectro de masas con diferentes m/z, lo que genera miles de espectros individuales en una única muestra. Sin embargo, para poder analizarlos de manera conjunta, es necesario que todos los píxeles compartan un mismo conjunto de valores de m/z. Por esta razón, el preprocesamiento de los datos en crudo realizado con el paquete r-MSI2 consiste en un conjunto de operaciones cuyo objetivo es reducir el ruido, corregir las variaciones técnicas y garantizar que los espectros de todos los píxeles sean comparables entre sí. El resultado de este proceso es la creación de una estructura común, generalmente conocida como “peak matrix” (pks), en la que cada fila representa un píxel y cada columna corresponde a un m/z. Las celdas de esta matriz contienen las intensidades de los m/z en los diferentes píxeles como se observa en la figura 6.




Figura 6: Fragmento (5x5) de la matriz de intensidades resultante (pks) tras el preprocesamiento de los datos crudos con el paquete rMSI2. Cada fila representa un píxel de la imagen, mientras que cada columna corresponde a un valor específico de m/z. En este caso, los m/z representados son: 105.0701, 106.9047, 108.9428, 109.9169 y 112.8960. Las celdas muestran las intensidades asociadas a dichos m/z en los primeros cinco píxeles de la imagen. La imagen de MSI de la derecha se trata de una representación en formato “Heat-Map” que representa la distribución espacial de las intensidades del m/z = 105.0701 en todos los píxeles de la pks. Fuente: [Elaboración propia con r-MSI2 en R].

Es destacable comentar que tras este preprocesamiento con r-MSI2 se ha llegado a la pks con dimensiones de 46,662 × 1,874. Estas 46,662 filas se corresponden con los píxeles que tendrán las imágenes de MSI. Por otro lado, las columnas se corresponden con las 1,874 m/z y cada

celda corresponde a las intensidades de estos en cada píxel. Por tanto, el total de intensidades que contiene la matriz es de 87,444,588 ($1,874 \times 46,662 = 87,444,588$). Esta matriz será la que se tratará con diferentes normalizaciones, reducciones de la dimensionalidad y algoritmos de clusterización para poder evaluar una combinación óptima y que pueda funcionar como un pipeline óptimo para tratamiento de datos de MSI.

5.3. Tratamiento de la pks mediante las normalizaciones TIC, RMS y MAX:

Tras el preprocesamiento con r-MSI2 y la obtención de la matriz pks, es posible representar la distribución espacial de los diferentes features y sus intensidades en el tejido, generando imágenes MSI como la mostrada en la Figura 6 para el m/z 105.0701. No obstante, las intensidades varían significativamente entre píxeles, presentando valores altos, bajos o incluso nulos, lo que dificulta la comparación directa y puede enmascarar diferencias biológicas relevantes.

Para corregir esta variabilidad y facilitar una interpretación más homogénea de las imágenes, se han aplicado distintos métodos de normalización que permiten corregir variaciones ajenas a la información biológica que aportan los datos. De hecho, diversos estudios han señalado la necesidad de estandarizar este paso, dada la gran variedad de enfoques utilizados en análisis MSI tras el preprocesamiento (Tobias & Hummon, 2020).

En este trabajo se han evaluado tres técnicas de normalización: normalización por TIC (“Total Ion Current”), normalización por RMS (“Root Mean Square”) y normalización por MAX (“Maximum Intensity”), con el objetivo de identificar el pipeline mencionado anteriormente.

Para cada píxel, se calcularon las métricas TIC, RMS y MAX para llevar a término las diferentes normalizaciones. El TIC representa la suma total de las intensidades de todos los m/z de un píxel. Por otro lado, el valor RMS corresponde a la raíz cuadrada del promedio de intensidades elevadas al cuadrado, proporcionando una media estadística de la intensidad de cada píxel. Finalmente, el valor MAX indica la intensidad más alta registrada en cada píxel.

Dado que la imagen contiene 46,662 píxeles, se obtuvieron 46,662 valores para cada una de estas métricas. En la Figura 7 se muestra la representación espacial de estos valores en la imagen MSI.




Figura 7: Representación de los 46,662 valores TIC, RMS y MAX en la imagen de MSI de la muestra. A) Representación de los 46,662 valores TIC; B) Representación de los 46,662 valores RMS; C) Representación de los 46,662 valores MAX. Fuente: [Elaboración propia con R].

Una vez calculados los valores TIC, RMS y MAX para cada píxel, se normalizaron las intensidades de la matriz pks dividiendo todos los valores de intensidad de cada píxel por su valor TIC, RMS y MAX correspondiente. Este proceso generó tres nuevas matrices normalizadas con las mismas dimensiones que la pks. Estas matrices se utilizaron en las etapas posteriores de reducción de dimensionalidad y agrupamiento para evaluar cómo influye cada método de normalización en la clasificación de la región tumoral y la estromática. Además, se mantuvo la matriz pks sin normalizar como referencia, para comparar su rendimiento frente a las matrices normalizadas.

5.4. Reducción de la dimensionalidad de los datos con PCA, t-SNE y UMAP:

Tras haber aplicado las diferentes normalizaciones por TIC, RMS y MAX, las matrices resultantes aún presentan una alta dimensionalidad con 1,874 m/z. Por ello, se han utilizado diversas técnicas de reducción de dimensionalidad que están siendo activamente estudiadas en el contexto de la MSI, como la PCA (“Principal Component Analysis”), t-SNE (“t-distributed Stochastic Neighbor Embedding”) y UMAP (“Uniform Manifold Approximation and Projection”). Estas técnicas permiten representar la información más relevante en un espacio reducido, facilitando su interpretación y gestión computacional.

En este estudio, la PCA ha sido aplicada a las tres matrices normalizadas y a la matriz pks sin normalizar. El objetivo de la PCA consiste en transformar el conjunto de los m/z en un sistema de componentes no correlacionados. Este proceso genera una nueva matriz reducida, donde las columnas representan los componentes principales, permitiendo conservar la información esencial del conjunto original. Para hacer esta transformación, la PCA se centra en relaciones lineales entre las diferentes variables y establece componentes sintéticas de las variables que más se correlacionan entre ellas. La figura 8 ilustra de forma visual este concepto para dejar claro el objetivo de la PCA, dejando en claro que las relaciones k-l y m-l se correlacionan entre ellas pudiendo dar lugar a 2 componentes diferentes.




Figura 8: Representación gráfica de relaciones lineales entre diferentes variables ejemplo: j, k, l y m. Fuente: [Figura 1.2 (Husson et al., 2011)]

Como se ha observado en la figura 8, cuando se trabaja con pocas variables es posible sacar conclusiones fácilmente. Sin embargo, en este estudio se trabajaba con muchas intensidades de cada una de las 4 matrices: la pks, la normalizada por TIC, la normalizada por RMS y la normalizada por MAX. Por esta razón, son necesarias herramientas como el paquete de R FactoMiner (Lê et al., 2008) para hacer esto.

FactoMiner recibe como entrada para hacer la PCA las 4 matrices y el número de componentes que se escoge, ya que es capaz de encontrar correlaciones lineales entre las intensidades de los diferentes m/z y transformarlos en el número de componentes que se seleccionan. El resultado que devuelve se trata de una matriz con un menor número de columnas.

Es destacable comentar que las primeras componentes son las que albergan una mayor varianza acumulada. Desde el punto de vista biológico, la varianza acumulada en diferentes componentes se trata del porcentaje de información biológica capturada al usar un número determinado de componentes. En este estudio se han seleccionado 4 y 100 componentes. En la figura 9 queda adjunto el porcentaje de varianza acumulada para estas 4 y 100 componentes.




Figura 9: Histogramas comparativos del porcentaje de varianza explicada por PCA en función de las normalizaciones y la pks sin normalizar. En la 9A se muestran los resultados para las 4 primeras componentes. En la 9B se muestran los resultados para las 100 primeras componentes. En el eje X de ambas quedan representadas diferentes barras para las diferentes normalizaciones aplicadas (TIC, RMS y MAX) y la no normalizada (pks). El eje Y corresponde a los diferentes porcentajes de varianza acumulada. Fuente: [Elaboración propia con R].

La selección de estas componentes se ha centrado en dos criterios fundamentales: (1) la práctica común en diferentes estudios de MSI, donde se suelen seleccionar 2-4 componentes para la reducción de la dimensionalidad por PCA; y (2) la evidencia proporcionada por un reciente estudio que combina la reducción por PCA con el aprendizaje profundo auto-supervisado (Seydoux et al., 2025). Dicho estudio señala que la restricción a las primeras 4 componentes puede excluir componentes de menor varianza que alberguen características débiles, pero significativas, como patrones moleculares raros que podrían ser interpretados erróneamente como ruido.

En base a la evidencia aportada por el estudio mencionado, se ha optado por la evaluación tanto de 4 como de 100 componentes en las matrices normalizadas y la matriz sin normalizar en el desarrollo y evaluación del pipeline. Esto ha permitido la reducción de los 1,874 features de las matrices descritas a 4 y a 100, proporcionando una mejora importante a nivel de gestión computacional. Además, la inclusión de las 100 componentes garantiza la retención de un porcentaje de varianza acumulada por encima del 70% en todas las normalizaciones como se observa en la figura 9B, permitiendo conservar gran parte de la información biológica en un espacio dimensional reducido.

Las mismas 4 matrices utilizadas previamente a la reducción por PCA, fueron sometidas a la reducción t-SNE. Para ello, se ha empleado el paquete de R Rtsne (Van Der Maaten, 2014) del repositorio de CRAN. La reducción de la dimensionalidad por t-SNE, al contrario que la PCA, se trata de un tipo de reducción de la dimensionalidad no lineal que preserva la estructura local

de los datos. Es decir, asegura que los píxeles que estaban cerca en el espacio original de alta dimensionalidad sigan estando cerca en el espacio reducido. Esto da la posibilidad a la t-SNE de revelar clústeres, incluso cuando las relaciones biológicas entre los datos son complejas. Para lograr esto, t-SNE utiliza diferentes transformaciones matemáticas. Estas transformaciones se basan en la comparación de las distancias entre píxeles en el espacio original y en el espacio reducido. Luego, se calcula la discrepancia de estas distancias siguiendo la función de minimización de divergencia de Kullback-Leibler(KL) (Jeong & Wu, 2024), lo que lleva a preservar la estructura local de los datos.

Rtsne utiliza como datos como entrada para hacer la reducción de la dimensionalidad son los mismos que los que utiliza FactoMiner para la PCA. El resultado que devuelve, al igual que la PCA, serán matrices con menor número de columnas. Las dimensiones seleccionadas para esta reducción han sido 2 y 3, ya que esta elección ha mostrado buenos resultados en estudios previos de MSI. Un ejemplo que respalda esta decisión es el trabajo de (Abdelmoula et al., 2016)

Además, se ha aplicado UMAP a las mismas matrices de datos utilizadas en las reducciones anteriores. El paquete de R usado para hacer UMAP se trata del paquete uwot (McInnes et al., 2018) de CRAN. Esta reducción es no lineal y busca preservar tanto la estructura local como la global de los datos, a diferencia de t-SNE, que se centra en conservar la estructura local. Para lograr esto, UMAP calcula las similitudes entre los píxeles en el espacio de alta dimensionalidad generando un grafo de vecinos más cercanos (Damrich & Hamprecht, 2021). UMAP minimiza la diferencia entre la estructura del grafo en alta y baja dimensión, de modo que las relaciones en el espacio original se mantengan.

Los datos que utiliza el paquete uwot como entrada son los mismos que los paquetes de las anteriores reducciones. El resultado se trata de las matrices resultantes con un menor número de columnas, ya que han sido reducidas a las componentes seleccionadas. El número de componentes seleccionadas en estas reducciones ha sido de 3 debido a que esta reducción de suele realizarse a 3 dimensiones diferentes estudios de MSI (Smets et al., 2020).

Tras aplicar los tres métodos de reducción de la dimensionalidad (PCA, t-SNE y UMAP), junto con la no reducción de la dimensionalidad a las cuatro matrices de datos (pks sin normalizar y las 3 matrices normalizadas), se obtuvieron un total de 24 matrices:

- 20 matrices reducidas (4 matrices $\times$ 5 configuraciones distintas: PCA con 4 componentes (PCA-4), PCA con 100 componentes (PCA-100), t-SNE con 2 componentes (t-SNE2), t-SNE con 3 componentes (t-SNE3), UMAP con 3 componentes (UMAP3).
- 4 matrices sin reducir: Normalizada por TIC (TIC), normalizada por RMS (RMS), normalizada por MAX (MAX) y sin normalizar (pks).

Estas matrices reducidas permitieron trabajar con un número significativamente menor de columnas, lo que facilitó tanto el análisis como la visualización de los resultados. En el Anexo I queda adjunta una tabla resumen para facilitar la comprensión de las reducciones de la dimensionalidad aplicadas.

5.5. Agrupamiento de datos mediante algoritmos de clusterización (K-Means, DBSCAN y HClust):

A partir de las proyecciones reducidas y sin reducción descritas al final del apartado 7.4, se han aplicado diferentes métodos de clusterización no supervisada con el objetivo de identificar agrupamientos moleculares relevantes que pudieran reflejar las diferencias biológicas de la región tumor y estromática en el tejido. Se les denomina no supervisados porque no requieren información previa o etiquetas sobre la muestra. Los algoritmos de clusterización han sido seleccionados debido a que son ampliamente usados en diferentes estudios de MSI. Estos algoritmos son: K-Means (“K-means clustering”), DBSCAN (“Density-Based Spatial Clustering of Applications with Noise”) y HClust (“Hierarchical Clustering”).

K-Means es un algoritmo de clusterización no jerárquico que agrupa los píxeles en un número predefinido de clústeres. Para ello, el algoritmo sigue un proceso iterativo: primero, se elige un número determinado de clústeres y se seleccionan puntos aleatorios o centroides iniciales. A continuación, cada píxel se asigna al centroide más cercano. Una vez asignados todos los píxeles, se recalculan nuevos centroides. Este proceso de asignación y actualización se repite hasta que los centroides dejan de cambiar, lo que indica que se ha alcanzado una solución estable.

Para ejecutar esta clusterización, se utilizó el paquete base de R (R Core Team & others, 2013), tomando como datos de entrada las 24 matrices de datos reducidas y sin reducir, junto con el número deseado de clústeres. La determinación del número de clústeres se ha basado en una doble validación: el método del codo (“Elbow method”) y una evaluación visual.

El método del codo aplica el algoritmo K-Means en un rango predefinido de clústeres. En este estudio, el rango aplicado ha sido de 2-10, ya que más de 10 clústeres se consideran excesivos para la división de una región tumor y estromática. Para cada iteración, se calcula la suma de cuadrados dentro del grupo (“Within-Cluster Sum of Squares”, WCSS) como medida del agrupamiento de los datos. En los diagramas del codo, WCSS se representa en el eje Y y el número de clústeres en el eje X. A medida que aumenta el número de clústeres, WCSS disminuye, ya que más clústeres tienden a capturar una mayor variabilidad de los datos, lo que resulta en un menor agrupamiento. Por esta razón, se suele identificar el número óptimo de clústeres en punto de inflexión de estos diagramas. No obstante, dado que la inflexión no siempre es clara, se complementó el análisis con una validación visual. Se generaron visualizaciones para un rango más amplio de 2 a 20 clústeres, observando que las configuraciones con 4, 7 y 8 clústeres mostraban la mejor correspondencia con la anotación patológica. En la figura 10 se muestran los diagramas del codo obtenidos para las matrices normalizadas por TIC, RMS y MAX, así como para la matriz pks. Es importante señalar que estos diagramas se elaboraron a partir de las matrices sin reducción, ya que la elección del número de clústeres se basa en las características originales de los datos.




Figura 10: Diferentes diagramas de ELBOW en los que el eje Y corresponde a la WCSS y el eje X a los diferentes clústeres sobre los que itera. En la 10A se observa el ELBOW de la matriz normalizada por MAX. En la 10B se observa el ELBOW de la matriz normalizada por RMS. En la 10C se observa el ELBOW de la matriz normalizada por TIC. En la 10D se observa el ELBOW de la matriz pks. Fuente: [Elaboración propia con R].

Como se observa en la Figura 10, todos los diagramas de ELBOW muestran patrones similares y no dejan claro un punto de inflexión para determinar el número óptimo de clústeres. Pero, se observa que a partir de 4 clústeres el descenso de WSS es más pronunciado, dando una mayor robusteza a la selección de 4, 7 y 8 clústeres de la validación visual.

DBSCAN es un algoritmo no supervisado que agrupa los píxeles en función de la densidad de los datos, identificando regiones en las que las observaciones están estrechamente relacionadas. A diferencia de K-Means, DBSCAN no requiere especificar el número de clústeres previamente, por lo que no es necesario recurrir a métricas para determinar un número óptimo. En su lugar, utiliza dos parámetros clave: *eps*, que define el radio de vecindad permitido, y *minPts*, el número de píxeles necesario para formar un clúster. Valores más altos de ambos, favorecen a la formación de clústeres más grandes y homogéneos, mientras que valores bajos hacen el algoritmo más estricto. Uno de los principales desafíos de DBSCAN es la selección adecuada de estos parámetros, ya que no existe un criterio universal en la bibliografía.

Para este estudio, se utilizó el paquete de R *dbscan* (Hahsler et al., 2019) de CRAN que utiliza los mismos datos de entrada que la segmentación por K-Means. Según la documentación de este paquete, es recomendable establecer un valor de *minPts* superior a la dimensionalidad de los datos. En un estudio muy similar (Hu et al., 2021) con matrices MSI reducidas y sin reducir, se empleó un valor fijo de *minPts* de 300. Siguiendo esa referencia, se probaron valores de 200, 300 y 400, observándose que un *minPts* de 400 ofrecía una segmentación más homogénea. Para estimar un valor adecuado de *eps* para cada matriz, se ha utilizado la función “*KNNdist()*” del paquete. Esta función calcula distancias de los vecinos más cercanos y estima un valor de *eps* para cada una de las 24 matrices de entrada.

HClust (“Hierarchical Clustering”) es un algoritmo que genera una estructura jerárquica llamada dendograma. A diferencia de K-Means, que agrupa los datos mediante centroides, Hclust construye una jerarquía basada en la distancia entre los datos. No obstante, al igual que K-Means, requiere especificar un número de clústeres para definir el punto de corte del dendograma y obtener una segmentación final. Antes de aplicar el algoritmo, se calcula una matriz de distancias entre todos los píxeles, generando una matriz de proximidad distinta para cada una de las matrices reducidas y sin reducir. A partir de estas matrices, el algoritmo agrupa iterativamente los píxeles más similares, formando clústeres que se van fusionando hasta que todos los datos se integran en una única estructura jerárquica. Esta jerarquía se representa en

forma de dendograma, el cual se corta en función del número de clústeres deseado para obtener la agrupación final. El paquete de R usado para hacer esta clusterización ha sido el fastcluster (Müllner, 2013) de CRAN, que únicamente necesita como datos de entrada las matrices de proximidad anteriormente descritas. Para el cálculo del número óptimo de clústeres se ha seguido una validación visual del clustering. La validación visual se ha hecho igual que la de K-Means, resultando en 4, 7 y 8 clústeres como los óptimos.

Una vez aplicados los métodos de agrupamiento descritos a las 20 matrices reducidas y las 4 matrices sin reducir, los resultados se han visualizado en las figuras 11, 13 y 15 de la sección de resultados. Estas representaciones han sido fundamentales para evaluar y optimizar el pipeline para el análisis de datos de MSI. En el Anexo II queda adjunta una tabla resumen para facilitar la comprensión de los algoritmos de segmentación utilizados.

5.6. Evaluaciones de las diferentes combinaciones descritas e identificación de un ión de la zona tumoral y correregistro del mismo:

Para determinar cuál de las combinaciones descritas en la figura 4 se ajusta mejor con la hipótesis y el objetivo principal del desarrollo de un pipeline, se han usado diferentes evaluaciones: la correspondencia visual de las segmentaciones de la imagen MSI con la anotación patológica, el tiempo computacional empleado y la media de Silhouette (Batool & Hennig, 2021).

Posteriormente, mediante la técnica estadística t de Student (“t-test”) con corrección FDR (False Discovery Rate) y Fold-Change, se han filtrado aquellos m/z con intensidades significativamente diferentes entre la región tumor y estromática, anotando un m/z significativo y con importancia biológica de la región tumoral con la base de datos HMDB.

En última instancia, para completar el objetivo adicional del estudio, se realizó el correregistro de este ión o m/z utilizando el paquete MSIreg de R, previamente mencionado en la introducción. Por tanto, el objetivo adicional de identificación de un m/z con importancia biológica de la región tumoral y el correregistro del mismo ha podido ser usado como una validación biológica del pipeline.

6. Resultados y Discusión:

6.1 Evaluaciones visuales según la comparativa con la imagen histopatológica:

Los resultados obtenidos de las segmentaciones en función de las diferentes combinaciones de métodos de normalización, de reducción de la dimensionalidad y de algoritmos de clusterización se muestran en las figuras 11,13 y 15.




Figura 11: Representación de las diferentes combinaciones de normalización y de reducción de la dimensionalidad con la clusterización por DBSCAN. Las columnas representan los diferentes métodos de reducción de la dimensionalidad con el número de componentes seleccionadas (PCA4, PCA100, UMAP3, TSNE2 y TSNE3), junto con la opción sin reducción (NR). Las filas de cada tabla representan los diferentes métodos de normalización (TIC, RMS y MAX), junto con los datos sin normalizar (pks). Fuente: [Elaboración propia con R].

En la figura 11, la segmentación del tejido sugiere que el algoritmo DBSCAN no proporciona una clusterización óptima. Esto se debe a que, tanto los datos sin reducir como las reducciones mediante PCA, t-SNE, no presentan un patrón de segmentación coherente. En algunos casos, la representación muestra un único color, lo que indica que el algoritmo no ha identificado clústeres sin lograr una segmentación. Es cierto que la reducción de la dimensionalidad mediante UMAP mejora los resultados de la segmentación para los datos normalizados y sin normalizar. Sin embargo, el número de clústeres generados es excesivo para diferenciar únicamente entre la región tumor y la estromática. Además, la estructura espacial de los clústeres no se asemeja a la morfología esperada en la imagen histopatológica, como se evidencia en la figura 12.




Figura 12: Comparativa entre las segmentaciones obtenidas mediante DBSCAN tras aplicar diferentes técnicas de normalización y la reducción UMAP3, junto con la imagen histopatológica. A) Sin normalizar y UMAP3; B) Normalizada por TIC y UMAP3; C) Normalizada por RMS y UMAP3; D) Normalizada por MAX y UMAP3; E) Imagen histopatológica con subregiones de la región estromática (Verde) e islotes neoplásicos de la región tumoral (Rojo). Fuente: [Elaboración propia con R].

En la figura 12A se observa que la reducción UMAP junto con la no normalización de los datos, no representa de forma adecuada la región estromática en comparación con la imagen histopatológica. En cambio, las figuras 12B, 12C y 12D con las diferentes normalizaciones muestran una mejora en la representación de la región tumoral y estromática. No obstante, el número de clústeres supera los 10, lo que complica el filtrado posterior de diferentes valores de m/z .

Esta complicación posterior en el filtrado de m/z se debe a que, cuanto mayor es el número de clústeres, más complejo resulta agruparlos en una región tumor y una estromática. Por ejemplo, en la figura 12D se utilizaron 10 clústeres, por lo que sería necesario reagruparlos en dos categorías principales (tumoral y estromática) para poder aplicar la prueba t de Student, ya que esta requiere comparar dos condiciones: una patológica y una sana.




Figura 13: Representación de las diferentes combinaciones de normalización y de reducción de la dimensionalidad con la clusterización por HClust. Las columnas de cada tabla representan los diferentes métodos de reducción de la dimensionalidad con el número de componentes seleccionadas (PCA4, PCA100, UMAP3, TSNE2 y TSNE3), junto con la opción sin reducir (NR). Las filas de cada tabla representan los diferentes métodos de normalización (TIC, RMS y MAX), junto con los datos sin normalizar (pks). La 13A es HClust con 4 clústeres, la 13B es HClust con 7 clústeres y la 13C es HClust con 8 clústeres. Fuente: [Elaboración propia con R].

En la figura 13, la segmentación del tejido con HClust muestra que las reducciones por PCA y los datos sin reducción no son óptimas, ya que no presentan un patrón de segmentación que pueda diferenciar la región estromática de la tumoral. Sin embargo, se observa que las reducciones de la dimensionalidad UMAP y t-SNE con las normalizaciones por RMS y MAX tienden a mostrar una mayor diferenciación espacial entre clústeres y una mayor similitud con la anotación histopatológica con algunas discrepancias. En la figura 14 se muestra la

combinación que más similitud presenta con la imagen histopatológica en las segmentaciones hechas con HClust.




Figura 14: Combinación de normalización RMS, junto con la reducción TSNE2 con la segmentación jerárquica a 4 clústeres, junto con la imagen histopatológica. La 14A representa la segmentación de los píxeles según HClust y el número de clústeres con diferentes colores. La 14B muestra la imagen histopatológica con los islotes neoplásicos de la región tumoral (Roja) y subregiones de la región estromática (Verde). Fuente: [Elaboración propia con R].

A pesar de la notable correspondencia visual entre la segmentación mostrada en la Figura 14A y lo anotado en la imagen histopatológica de la Figura 14B, persisten ciertas discrepancias que dificultan la diferenciación precisa entre la región tumoral y estromática. En la Figura 14A, la región tumoral se distribuye principalmente entre los clústeres 3 y 4, lo que permite una identificación parcial de esta área. Sin embargo, la correspondencia entre la región estromática y los clústeres 1 y 2 no es tan clara. Específicamente, el clúster 1 no solo abarca las subregiones estromáticas anotadas por el patólogo, sino que también incluye zonas correspondientes al fondo blanco de la imagen histopatológica. Estas zonas corresponden a la matriz depositada para la ionización mediante láser, tal como se explicó en la introducción de esta memoria.

La razón principal de estas discrepancias radica en el uso de algoritmos de clusterización no supervisada, que agrupan los datos únicamente en función de similitudes matemáticas, sin utilizar etiquetas biológicas previas. Como consecuencia, estos algoritmos no distinguen entre tejido y fondo, lo que puede llevar a que áreas biológicamente distintas, como el fondo y ciertas áreas del tejido, queden agrupadas en el mismo clúster.




Figura 15: Representación de las diferentes combinaciones de normalización y de reducción de la dimensionalidad con la clusterización por K-Means. Las columnas de cada tabla representan los diferentes métodos de reducción de la dimensionalidad con el número de componentes seleccionadas (PCA4, PCA100, UMAP3, TSNE2 y TSNE3), junto con la opción sin reducir (NR). Las filas de cada tabla representan los diferentes métodos de normalización (TIC, RMS y MAX), junto con los datos sin normalizar (pks). La 15A es K-Means con 4 clústeres, la 15B es K-Means con 7 clústeres y la 15C es K-Means con 8 clústeres. Fuente: [Elaboración propia con R].

La figura 15 muestra que las segmentaciones con el algoritmo de clusterización K-Means son más detalladas con 7 y 8 clústeres. Al igual que Hclust, las reducciones de la dimensionalidad con UMAP y t-SNE son las que tienden a generar segmentaciones más estructuradas y delimitadas. Además, en la figura 15C se observa que la combinación de la normalización MAX y la reducción por UMAP, presenta una clusterización K-Means con 8 clústeres con una

alta correspondencia con la anotación histopatológica. Esta correspondencia se ilustra en la figura 16 de forma más clara.




Figura 16: Combinación de la normalización MAX con la reducción UMAP3 con la segmentación K-Means a 8 clústeres, junto con la imagen histopatológica. La 16A representa la segmentación de los píxeles según K-Means y el número de clústeres con diferentes colores. La 16B representa la anotación histopatológica con islotes neoplásicos de la región tumoral (Roja) y subregiones de la región estromática (Verde). Fuente: [Elaboración propia con R].

La Figura 16A muestra la segmentación considerada como adecuada según la evaluación visual realizada con el algoritmo K-Means. En esta segmentación, los clústeres 2, 5 y 6 corresponden a la región tumoral, mientras que los clústeres 7, 8 y 1 se asocian a la región estromática. Por otro lado, los clústeres 3 y 4 se identifican principalmente con el fondo de la imagen histopatológica, es decir, con la matriz MALDI. Esta clasificación clara de ambas regiones valida la hipótesis del estudio, demostrando que es posible diferenciar computacionalmente el área tumoral y estromática en una muestra de cáncer de vejiga urinario mediante el uso de técnicas de segmentación automática no supervisada.

En resumen, los resultados obtenidos mediante los diferentes métodos de clusterización muestran que las combinaciones basadas en UMAP o t-SNE junto con normalizaciones por RMS o MAX tienden a producir segmentaciones más consistentes con la imagen histopatológica. En particular, la combinación de K-Means con reducción por UMAP y normalización por MAX ofrece la mejor correspondencia visual, diferenciando de manera clara la región tumoral, la estromática y la matriz MALDI. Por ello, esta configuración permite la

aplicabilidad de este enfoque para la segmentación automática en estudios de cáncer de vejiga, cumpliendo con el objetivo principal.

6.2 Evaluación según el coste computacional:

El coste computacional asociado a las distintas combinaciones, junto con los diferentes algoritmos de clusterización empleados, resulta elevado. Por este motivo, se ha incluido otra evaluación orientada a identificar la combinación más eficiente desde el punto de vista computacional. Esta evaluación es fundamental para cumplir con el objetivo principal del estudio: el desarrollo de un pipeline robusto y práctico para la segmentación automatizada de imágenes histológicas. El ordenador empleado para hacer todas las combinaciones descritas presenta una RAM de 512Gb DDR4 3200 MHz y un procesador AMD Threadripper PRO 5975WX.




Figura 17: Diagrama de barras con los tiempos de ejecución (en segundos) de los algoritmos de clustering (K-Means, HClust y DBSCAN) en función del método de reducción de dimensionalidad aplicado con el número de componentes seleccionado (No reducida, PCA4, PCA100, t-SNE2, t-SNE3 y UMAP3). El eje Y es el tiempo en segundos y está representado en escala logarítmica (base 10). El eje X corresponde a los diferentes métodos de clustering (K-Means, HClust y DBSCAN). Los colores de las barras corresponden a las diferentes reducciones de la dimensionalidad aplicadas y se pueden observar en la leyenda. Fuente: [Elaboración propia R].

Como se observa en la Figura 17, el tiempo de ejecución varía considerablemente según el algoritmo de clustering y la técnica de reducción de dimensionalidad utilizada. En particular,

trabajar sin reducción dimensional provoca tiempos de ejecución significativamente más altos, como es evidente. Por tanto, esto justifica el uso de una escala logarítmica en el eje Y para poder diferenciar las barras de las reducciones más bajas. Esta transformación facilita la visualización de los tiempos de ejecución de los métodos de reducción más rápidos, como la PCA y UMAP, los cuales serían difíciles de apreciar en una escala lineal convencional. Además, se observa que K-Means presenta un menor tiempo de ejecución, tanto con reducción de dimensionalidad como sin ella, en comparación con los algoritmos de clusterización jerárquica y DBSCAN.

Por tanto, esto refuerza la evaluación visual previa, ya que demuestra que la combinación de UMAP con la segmentación K-Means mostrada en la figura 16A no solo respalda la hipótesis inicial, sino que también permite la gestión computacional más eficiente.

6.3 Evaluación según la media de Silhouette:

La media de Silhouette emplea como una evaluación complementaria a las dos evaluaciones anteriores, con el objetivo de confirmar que la combinación de la figura 16A cumple con la hipótesis de estudio y alcanza el objetivo principal del trabajo.

Esta media es una métrica que permite cuantificar la calidad de segmentación obtenida a partir de los algoritmos de clusterización, es decir evalúa lo separado que están los clústeres entre sí. Por tanto, la media de Silhouette es válida para la evaluación de todas las segmentaciones hechas a lo largo del estudio.

Esta métrica calcula, para cada píxel, la distancia media a los demás píxeles de su mismo clúster (distancia intra-clúster) y la distancia media a otros píxeles del clúster más cercano (distancia inter-clúster). El valor Silhouette resultante está entre -1 y 1, donde los valores cercanos a 1 son los mejores en términos de segmentación. En la figura 21 se observa la media de Silhouette resultante para cada una de las combinaciones probadas con las diferentes técnicas de segmentación.




Figura 18: Diagrama de barras del promedio de Silhouette en función de las distintas combinaciones de métodos de normalización, reducción de la dimensionalidad y los algoritmos de clusterización con diferente número de clústeres. Los métodos de normalización son: TIC, RMS, MAX y sin normalizar (pks). Los métodos de reducción de la dimensionalidad con el número de componentes seleccionado son: UMAP3, t-SNE2, t-SNE3, PCA4, PCA100 y la no reducción (NR). Los algoritmos de clusterización son: Hclust (HC), K-Means (KM) y DBSCAN (DB). Los números de clústeres analizados son: 4, 7 y 8. El número de clúster 0 en DBSCAN se refiere a que es un método que el número de clústeres no se define de forma previa. El eje Y corresponde a los valores de la media de Silhouette, mientras que el eje X a las diferentes combinaciones evaluadas. Los colores de las barras varían en función del enfoque de normalización (TIC, RMS, MAX y pks sin normalizar) y se observan en la leyenda. Fuente: [Elaboración propia con EXCEL y datos de R].

En la Figura 18 se observa que algunas combinaciones alcanzan valores de la media de Silhouette muy cercanos a 1. En principio, se esperaría que estas combinaciones correspondieran a las segmentaciones más satisfactorias. Sin embargo, muchas de estas combinaciones corresponden a la segmentación con Hclust sin reducción de dimensionalidad o con reducciones mediante PCA. Tal y como se ha mostrado en la Figura 13, estas segmentaciones no resultan óptimas desde el punto de vista biológico, ya que no permiten diferenciar adecuadamente entre la región tumoral y la estromática. Por tanto, en este estudio se evidencia que los valores más altos de Silhouette no siempre se corresponden con patrones de segmentación biológicamente relevantes. Esta discrepancia suele producirse cuando el algoritmo asigna la mayoría de los píxeles a un único clúster lo que genera valores de esta métrica artificialmente elevados, pero con una segmentación poco informativa para el análisis histopatológico.

A pesar de esta problemática, en la figura 18 se puede identificar que algunas combinaciones que incluyen la reducción UMAP junto con las segmentaciones K-Means o HClust presentan valores cercanos a 0,5 de manera consistente. Esta consistencia de UMAP con K-Means y Hclust queda reflejada en la figura 19.




Figura 19: Diagrama de barras del promedio de Silhouette en función de las distintas combinaciones de métodos de normalización (TIC, RMS, MAX) y sin normalizar (pks) con la reducción de dimensionalidad con UMAP3, utilizando los algoritmos de clusterización jerárquica (HC) y K-Means (KM) con diferentes números de clústeres (4, 7 y 8). Fuente: [Elaboración propia con EXCEL y datos de R].

En la figura 19 se observa que las combinaciones con la reducción de la dimensionalidad UMAP con 3 componentes muestra valores de la silueta intermedios (0.4-0.5) de forma consistente. Esta uniformidad permite entender la razón por la cuál en las evaluaciones visuales la reducción de la dimensionalidad UMAP presentaba una mejora de los resultados en términos de segmentación.

Por otro lado, es importante señalar que el pipeline seleccionado como óptimo según las evaluaciones visuales y el análisis del coste computacional alcanza una media de silueta de 0.36, inferior a la de otros métodos. Sin embargo, este resultado pone de manifiesto que un mayor valor del índice de silueta no siempre se traduce en una segmentación biológicamente relevante.

6.4 Filtrado de m/z con interés biológico:

Una vez evaluadas las distintas combinaciones de técnicas de transformación de los datos y seleccionada una de ellas como un pipeline automatizable para futuras segmentaciones, se procede a la identificación de diferentes m/z representativos de la región tumoral y estromal de la sección de tejido.

Como ya se comentó anteriormente en la figura 16A, los clústeres 2, 5 y 6 corresponden a la región tumoral, mientras que los clústeres 7, 8 y 1 se asocian a la región estromática. Para identificar los m/z diferenciales entre ambas regiones, se aplicó un t-test para cada uno de los m/z, comparando las intensidades medias de los mismos entre los píxeles asignados a los

clústeres tumorales y aquellos asignado a los clústeres estromáticos. Estas pruebas estadísticas permiten evaluar si las diferencias de intensidad observadas entre ambas regiones son significativas, y por tanto si un determinado m/z puede considerarse característico de una de las dos zonas del tejido. Los p- valores resultantes de estos t-test, han sido corregidos con el ajuste FDR (“False Discovery Rate”) (Chen, 2020) . Este ajuste permite controlar la proporción esperada de falsos positivos entre los que se consideran significativos. Además, se calcula el log en base 2 del Fold Change (FC) que se trata de una medida para cuantificar cuanto ha aumentado o disminuido la intensidad de un m/z entre la región tumor y estromática. El cálculo de los FC de los diferentes m/z (Aguilan et al., 2020) se calcula dividiendo la media de intensidad de un m/z en los píxeles de la región tumor entre la media de intensidad del m/z en los píxeles de la región estromática. Por tanto, valores con $\log_2(FC) \geq 1$ indican m/z con mayor intensidad en la región tumor, mientras que $\log_2(FC) \leq -1$ indican m/z con mayor intensidad en la región estromática. Finalmente, después de calcular los valores p ajustados mediante el método FDR y de obtener los valores de Fold Change (FC) para cada m/z, se procede a filtrar los m/z que presenten valores p inferiores a 0.01 y $\log_2(FC) \geq 1$ o $\log_2(FC) \leq -1$. Estos filtros permiten obtener m/z altamente significativos en cuanto a diferencia de intensidad entre ambas regiones ($p < 0.01$) y los que tienen mayor intensidad en la región tumor o estromática según su $\log_2(FC)$. Estos m/z filtrados han sido representados de color rojo en un Volcano plot en la figura 20.




Figura 20: Volcano plot que representa los resultados del análisis diferencial de intensidad de los m/z entre las regiones tumoral y estromática. En el eje X se muestra el logaritmo en base 2 del Fold Change ($\log_2(FC)$) y en el eje Y se representa el valor $-\log_{10}$ del p-valor ajustado por FDR. Los puntos rojos corresponden a los features filtrados. Fuente: [Elaboración propia con R].

En la figura 20 se observan los m/z significativos con mayor intensidad en la región tumoral en la parte derecha ($\log_2(FC) \geq 1$) y los m/z significativos con menor intensidad en la región estromática ($\log_2(FC) \leq -1$) en la parte izquierda. Cabe destacar que, en el eje Y del Volcano

Plot, se aplica el logaritmo negativo en base 10 a los p-valores ajustados. Este ajuste se realiza para que la escala sea más comprensible y permita una mejor visualización de los valores significativos.

Gracias a estos filtros, fueron cribados 204 m/z con una diferencia significativa de intensidades en la zona tumor y en la estromática de los 1,874 que había en el conjunto de datos sin transformar. De estos 204, 124 presentan mayores intensidades en la región tumor y 80 en la región estromática. Este resultado de más m/z significativos en la región tumoral refleja una significancia biológica evidente basada en que las células tumorales tienden a tener un metabolismo muy activo.

6.5. Anotación en HMDB y corregistro:

Adicionalmente al objetivo principal de desarrollar un pipeline, existe el segundo objetivo planteado, centrado en la identificación y corregistro de un m/z con importancia biológica en la región tumoral y que ha permitido hacer la validación biológica del pipeline. Por esta razón, los 124 m/z con intensidad elevada en la región tumoral han sido anotados con la base de datos de HMDB.

Tras comparar estos m/z con la base de datos HMDB, se han obtenido varias listas con los posibles metabolitos asociados a cada uno. Es importante destacar que se habla de posibles metabolitos porque en MSI los valores de m/z detectados no corresponden a la molécula intacta. Esto es debido a que esta ionizada positivamente conformando aductos con iones positivos (como Na^+ o K^+) y puede haber isotopos naturales de la misma.

Los posibles metabolitos encontrados en su mayoría son de la familia lipídica. Esto es debido a la gran presencia celular en la zona y, por tanto, de membranas plasmáticas. Algunos de estos lípidos presentan modificaciones que pueden tener interés como potenciales biomarcadores. Una de las modificaciones más destacadas identificadas en este estudio corresponde a la fosfatidiletanolamina dimetilada (PE-NMe₂). La PE-NMe₂ es una forma metilada de la fosfatidiletanolamina (PE), en la que el grupo etanolamina ha recibido dos grupos metilo en el nitrógeno. Este lípido actúa como intermediario en la vía de síntesis de la fosfatidilcolina (PC), un fosfolípido esencial para el mantenimiento de la estructura y la fluidez de las membranas celulares. En la figura 21 se puede observar la vía metabólica de biosíntesis de PC a partir de sucesivas metilaciones de la PE.




Figura 21: Metilación secuencial de la fosfatidiletanolamina (PE) en la biosíntesis de fosfatidilcolina (PC). A) Estructura de la fosfatidiletanolamina (PE) con el grupo amino ($-\text{NH}_3^+$) sin modificar. B) Monometilfosfatidiletanolamina (MMPE o PE-NMe) tras la primera metilación ($-\text{NH}_2^+\text{CH}_3$). C) Dimetilfosfatidiletanolamina (DMPE o PE-NMe₂) después de la segunda metilación ($-\text{NH}^+(\text{CH}_3)_2$). D) Fosfatidilcolina (PC) resultante de la tercera metilación ($-\text{N}^+(\text{CH}_3)_3$), con el grupo colina completo. La enzima Fosfatidiletanolamina N-metiltransferasa (PEMPT) es la responsable de esta vía de metilación. Fuente: [Adaptada de la figura 1 (Kwarteng et al., 2023)].

El interés despertado por la PE-NMe₂ encontrada en la muestra, se debe al hecho de que un estudio reciente (Benabdelkamel et al., 2024), en el que se hizo una descripción del perfil metabolómico de tejido de cáncer de endometrio, identificó este lípido significativamente más elevadas con respecto a los controles.

Según los resultados de HMDB, se han anotado diferentes m/z que se corresponden con la PE-NMe₂. Para realizar el correregistro, se ha seleccionado uno de los m/z más representativos en los pixeles de la zona tumoral de la imagen de MSI para facilitar el correregistro del mismo. El m/z seleccionado se trata del 1,486 de los 1,875 de los datos originales, con un valor m/z de 784.5271. En la figura 22 se puede observar la representación de este m/z en la imagen MSI y el correregistro del mismo con la imagen histopatológica.




Figura 22: La 22A es la imagen de MSI en formato “Heat-Map” con intensidad obtenida por píxel para el m/z con valor de 782.5117, mostrando la distribución espacial de este m/z en la zona tumoral del tejido. La 22B es el proceso de corrección entre la imagen histológica (arriba izquierda) y la imagen MSI (arriba derecha) del mismo corte de tejido. Abajo se muestran las superposiciones antes (izquierda) y después (derecha) del corrección. Fuente: [Elaboración propia con R].

En la figura 22B se puede observar cómo, antes del corrección, la superposición de la imagen muestra un claro desajuste entre las estructuras anatómicas y moleculares. Sin embargo, tras la aplicación del corrección, se logra una alineación parcial mucho más precisa entre ambas modalidades de imagen. Es importante comentar que el corrección ejecutado no es del todo preciso, pero es suficiente para poder concluir que ambas imágenes corresponden a la sección de la muestra de cáncer de vejiga urinario y deja en clara la distribución de este m/z en la zona tumoral.

6.6. Comparaciones con otros estudios, limitaciones y perspectivas futuras:

La hipótesis planteada en este estudio sugiere que, mediante el análisis computacional de imágenes de MSI, es posible la segmentación de la región tumor y estromática de una muestra de cáncer de vejiga urinario. Los resultados obtenidos han demostrado que la combinación de normalización de los datos por MAX con la reducción de la dimensionalidad UMAP y la segmentación no supervisada por K-Means permiten confirmar dicha hipótesis. Entre todas las combinaciones expuestas en la figura 4, esta ha demostrado un mayor potencial para ser usada como un pipeline para la segmentación automatizada de imágenes de MSI debido a la eficiente gestión computacional, a la consistencia de la media de Silhouette de la reducción de la dimensionalidad UMAP y a la validación visual en este ejemplo de neoplasia. Por otro lado, este pipeline ha demostrado su aplicabilidad biológica identificando 204 valores de m/z con

diferencias significativas de intensidad entre la región tumoral y estromática. Uno de estos valores ha sido anotado como una PE-NMe₂, un lípido que ha sido identificado en otras neoplasias como el cáncer de endometrio, lo que refuerza su potencial como biomarcador. Además, uno de los m/z correspondientes a este lípido ha sido corregistrado a la imagen histopatológica, cumpliendo el objetivo adicional de identificación y correregistro de un m/z con relevancia biológica en la región tumoral.

En la literatura científica, existen estudios como el de (Smets et al., 2019) que han comparado diferentes técnicas de reducción de la dimensionalidad, concluyendo que UMAP genera segmentaciones de datos de mayor calidad que t-SNE y la PCA en grandes conjuntos de datos con más de 100,000 píxeles. Por tanto, este estudio, al igual que los resultados expuestos en este proyecto, refuerzan la idea de que la reducción de la dimensionalidad UMAP incluida en el pipeline puede ser escalable a otros conjuntos de datos. Otras referencias bibliográficas como la de (Xu et al., 2024) han evaluado diferentes combinaciones de métodos de reducción de la dimensionalidad (PCA y t-SNE) y algoritmos de agrupamiento (K-Means y HClust), observando buenos resultados de la t-SNE con HClust tanto a nivel visual como a nivel de métricas de agrupamiento. No obstante, en los resultados de este proyecto, t-SNE junto con HClust no ha proporcionado una segmentación clara ni consistente en el tejido. Esta discrepancia puede deberse a la sensibilidad de t-SNE a sus parámetros y a su menor capacidad de preservar estructuras frente a UMAP.

A pesar de los resultados positivos, este trabajo no está exento de limitaciones. En primer lugar, el análisis se ha realizado sobre una única muestra, lo que impide una generalización robusta de los resultados y dificulta la evaluación de su escalabilidad a otros conjuntos de datos. Además, el uso de métodos de segmentación no supervisados, sin información anatómica previa, implican que las segmentaciones sean aproximaciones biológicas. Esto puede dar lugar a resultados no coherentes con la biología del tejido como ocurre en la asignación de clústeres por HClust explicada en la figura 17A. Finalmente, como última limitación es importante destacar el uso de la métrica Silhouette como validación de las segmentaciones debido a que altos valores no se corresponden con segmentaciones aceptadas desde el punto de vista biológico.

Ante estas limitaciones, se proponen estudios futuros que puedan probar este pipeline a otros conjuntos de datos para validar la escalabilidad de este. Aparte, se propone una mayor

investigación en herramientas de segmentación supervisada basada en etiquetas biológicas y en el desarrollo de nuevas métricas de segmentación que puedan ser más competentes que Silhouette a nivel biológico.

7.Conclusiones:

Este estudio ha confirmado la hipótesis de partida, ya que el análisis bioinformático de datos MSI ha permitido segmentar computacionalmente la región tumoral y la estromática de la muestra de cáncer de vejiga urinaria. Además, se ha cumplido el objetivo principal del trabajo mediante la evaluación y desarrollo de un pipeline de segmentación automática, basado en la combinación de la normalización MAX con la reducción de la dimensionalidad UMAP y la clusterización mediante K-Means.

Por otro lado, este pipeline ha demostrado su aplicabilidad biológica, permitiendo identificar 204 m/z con diferencias significativas de intensidad entre la región tumoral y la estromática. Uno de estos, con mayor intensidad en la región tumoral, ha sido anotado como un lípido de interés previamente descrito en otras neoplasias. Este lípido se trata del PE-NMe2 y su distribución en la región tumoral ha sido corregistrado con la imagen histopatológica, cumpliendo así con el objetivo adicional del estudio.

En conjunto, este trabajo demuestra que el uso del pipeline propuesto puede mejorar la caracterización espacial de tejidos tumorales mediante la técnica de MSI. Este enfoque representa un avance hacia la automatización del análisis de datos de MSI y sienta una base sólida para futuras investigaciones orientadas a la detección de biomarcadores es y a la mejora del registro imagenológico en contextos clínicos y de investigación.

Finalmente, cabe mencionar que el código utilizado durante el desarrollo del pipeline se encuentra en un repositorio público de código online, GitHub. La dirección para poder acceder a este código es: https://github.com/adrianmarman/TFG_Adrian_Manzano_Mart-nez_URV

8.Autoevaluación:

La realización de este TFG ha supuesto para mí un reto tanto académico como personal. Me mostré interesado en el grupo Mil@b porque quería explorar el campo de la bioinformática y de las Ciencias Ómicas, motivado por mi experiencia previa en la plataforma de “Mass Spectroetry and Proteomics” en el IRB de Barcelona bajo la supervisión de la Dra. Marta Vilaseca Casas. Mis expectativas estaban centradas en aplicar los conocimientos adquiridos durante el grado en un contexto real de investigación, desarrollar un enfoque autónomo y adquirir experiencia en el manejo de herramientas computacionales avanzadas.

A lo largo del desarrollo del TFG, he adquirido competencias técnicas en la evaluación y diseño de un pipeline bioinformático automatizado para la segmentación de imágenes MSI en el contexto metabolómico. He aprendido a aplicar distintos métodos de normalización, reducción de dimensionalidad (PCA, t-SNE, UMAP) y algoritmos de agrupamiento no supervisados (K-Means, DBSCAN, HClust), así como a evaluar los resultados mediante métricas cuantitativas (índice de Silhouette) y validación visual. Además, he implementado un análisis estadístico para la detección de m/z diferenciales y he explorado el corregistro de señales moleculares con imágenes histológicas.

También he fortalecido mi capacidad para la búsqueda de literatura científica, la interpretación crítica de resultados y la justificación de decisiones metodológicas. Trabajar en MSI y con grandes matrices de datos, me ha obligado a ser más rigurosos en la gestión del código, el procesamiento computacional y el uso eficiente de recursos. He aprendido a resolver problemas de forma autónoma, a consultar documentación técnica y a enfrentar situaciones en las que no hay una única respuesta correcta.

Desde un punto de vista personal, este proyecto ha representado un crecimiento importante y me ha permitido desarrollar la autonomía, la organización del trabajo, la perseverancia y la capacidad de adaptación que hay que tener en el mundo científico. Además, considero que he cumplido los objetivos marcados y que este trabajo representa la síntesis del tipo profesional que aspiro a ser. Sin embargo, soy consciente de que aún tengo margen de mejora en algunos aspectos técnicos en MSI, así como en la gestión de código informático. En definitiva, este TFG me ha permitido confirmar mi vocación hacia el análisis computacional de datos biológicos, y me ha motivado a la selección de un máster en Bioinformática. Por todo esto, puedo decir que estoy satisfecho con el trabajo realizado y con el aprendizaje adquirido.

9. Bibliografía y Webgrafía:

1. Abdelmoula, W. M., Balluff, B., Englert, S., Dijkstra, J., Reinders, M. J. T., Walch, A., McDonnell, L. A. & Lelieveldt, B. P. F. (2016). Data-driven identification of prognostic tumor subpopulations using spatially mapped t-SNE of mass spectrometry imaging data. *Proceedings of the National Academy of Sciences*, 113(43), 12244–12249. <https://doi.org/10.1073/pnas.1510227113>
2. Aguilan, J. T., Kulej, K. & Sidoli, S. (2020). Guide for protein fold change and p-value calculation for non-experts in proteomics. *Molecular Omics*, 16(6), 573–582. <https://doi.org/10.1039/D0MO00087F>
3. Batool, F. & Hennig, C. (2021). Clustering with the average silhouette width. *Computational Statistics & Data Analysis*, 158, 107190. <https://doi.org/10.1016/j.csda.2021.107190>
4. Benabdelkamel, H., Jaber, M. A., Akkour, K., AlMalki, R. H., Alfadda, A. A., Masood, A., Joy, S. S., Alhalal, H., Alwehaibi, M. A., Arafah, M. & others. (2024). Metabolomic profiling of blood plasma in females with hyperplasia and endometrial cancer. *Metabolites*, 14(2), 109. <https://doi.org/10.3390/metabo14020109>
5. Chabala, J. M., Edward, S., Levi-Setti, R., Lodding, A., Lundgren, T., Norén, J. G. & Odelius, H. (1988). Elemental imaging of dental hard tissues by secondary ion mass spectrometry. *Swedish Dental Journal*, 12(5), 201–212.
6. Chen, X. (2020). False discovery rate control for multiple testing based on discrete p-values. *Biometrical Journal*, 62(4), 1060–1079. <https://doi.org/10.1002/bimj.201900163>
7. Damrich, S. & Hamprecht, F. A. (2021). On UMAP's true loss function. *Advances in Neural Information Processing Systems*, 34, 5798–5809.
8. Dyrskjøl, L., Hansel, D. E., Efstathiou, J. A., Knowles, M. A., Galsky, M. D., Teoh, J. & Theodorescu, D. (2023). Bladder cancer. *Nature Reviews Disease Primers*, 9(1), 58. <https://doi.org/10.1038/s41572-023-00468-9>
9. Gemperline, E., Rawson, S. & Li, L. (2014). Optimization and comparison of multiple MALDI matrix application methods for small molecule mass spectrometric imaging. *Analytical Chemistry*, 86(20), 10030–10035. <https://doi.org/10.1021/ac5028534>
10. Gigante, E., Cazier, H., Albuquerque, M., Laouirem, S., Beaufrère, A. & Paradis, V. (2023). MALDI imaging, a powerful multiplex approach to decipher intratumoral heterogeneity: combined hepato-cholangiocarcinomas as proof of concept. *Cancers*, 15(7), 2143. <https://doi.org/10.3390/cancers15072143>
11. Gonçalves, J. P. L., Bollwein, C., Noske, A., Jacob, A., Jank, P., Loibl, S., Nekljudova, V., Fasching, P. A., Karn, T., Marmé, F. & others. (2023). Characterization of hormone receptor and HER2 status in breast cancer using mass spectrometry imaging. *International Journal of Molecular Sciences*, 24(3), 2860. <https://doi.org/10.3390/ijms24032860>
12. Hahsler, M., Piekenbrock, M. & Doran, D. (2019). dbscan: Fast density-based clustering with R. *Journal of Statistical Software*, 91, 1–30. <https://doi.org/10.18637/jss.v091.i01>

13. Hamidi, H., Senbabaoglu, Y., Beig, N., Roels, J., Manuel, C., Guan, X., Koeppen, H., Assaf, Z. J., Nabet, B. Y., Waddell, A. & others. (2024). Molecular heterogeneity in urothelial carcinoma and determinants of clinical benefit to PD-L1 blockade. *Cancer Cell*, 42(12), 2098–2112. <https://doi.org/10.1016/j.ccell.2024.10.016>
14. Hu, H. & Laskin, J. (2022). Emerging computational methods in mass spectrometry imaging. *Advanced Science*, 9(34), 2203339. <https://doi.org/10.1002/adv.202203339>
15. Hu, H., Yin, R., Brown, H. M. & Laskin, J. (2021). Spatial Segmentation of Mass Spectrometry Imaging Data by Combining Multivariate Clustering and Univariate Thresholding. *Analytical Chemistry*, 93(7), 3477–3485. <https://doi.org/10.1021/acs.analchem.0c04798>
16. Humphries, M. P., Maxwell, P. & Salto-Tellez, M. (2021). QuPath: The global impact of an open source digital pathology system. *Computational and Structural Biotechnology Journal*, 19, 852–859. <https://doi.org/10.1016/j.csbj.2021.01.022>
17. Husson, F., Lê, S. & Pagès, J. (2011). *Exploratory multivariate analysis by example using R* (Vol. 15). CRC press Boca Raton.
18. Jeong, S. & Wu, H.-T. (2024). Convergence analysis of t-SNE as a gradient flow for point cloud on a manifold. *ArXiv Preprint ArXiv:2401.17675*. <https://doi.org/10.48550/arXiv.2401.17675>
19. Kwarteng, D. O., Gangoda, M. & Kooijman, E. E. (2023). The effect of methylated phosphatidylethanolamine derivatives on the ionization properties of signaling phosphatidic acid. *Biophysical Chemistry*, 296, 107005. <https://doi.org/10.1016/j.bpc.2023.107005>
20. Lakkimsetty, S. S., Weber, A., Bemis, K. A., Stehl, V., Bronsert, P., Föll, M. C. & Vitek, O. (2024). MSIreg: an R package for unsupervised coregistration of mass spectrometry and H&E images. *Bioinformatics*, 40(11), btae624. <https://doi.org/10.1093/bioinformatics/btae624>
21. Lê, S., Josse, J. & Husson, F. (2008). FactoMineR: an R package for multivariate analysis. *Journal of Statistical Software*, 25, 1–18. <https://doi.org/10.18637/jss.v025.i01>
22. Legeais, J. M., Hallegot, P., Chabala, J., Renard, G., Levi-Setti, R. & Galle, P. (1989). Trifluorothymidine localization in the rabbit cornea by secondary ion mass spectrometry imaging microanalysis. *Current Eye Research*, 8(9), 971–973.
23. Levi-Setti, R., Crow, G. & Wang, Y. L. (1985). Progress in high resolution scanning ion microscopy and secondary ion mass spectrometry imaging microanalysis. *Scanning Electron Microscopy*, 1985(2), 6.
24. LibreTexts. (2023). Fuentes de iones. Retrieved February 28, 2025, from [https://espanol.libretexts.org/Quimica/Qu%C3%ADmica_Anal%C3%ADtica/Anal%C3%A1lisis_Instrumental_\(LibreTextos\)/20%3A_Espectrometr%C3%ADa_de_Masa_Molecular/20.02%3A_Fuentes_de_iones](https://espanol.libretexts.org/Quimica/Qu%C3%ADmica_Anal%C3%ADtica/Anal%C3%A1lisis_Instrumental_(LibreTextos)/20%3A_Espectrometr%C3%ADa_de_Masa_Molecular/20.02%3A_Fuentes_de_iones)
25. Lin, B.-J., Kuo, T.-C., Chung, H.-H., Huang, Y.-C., Wang, M.-Y., Hsu, C.-C., Yao, P.-Y. & Tseng, Y. J. (2023). MSIR: automatic registration service for mass spectrometry imaging and histology. *Analytical Chemistry*, 95(6), 3317–3324. <https://doi.org/10.1021/acs.analchem.2c04360>

26. McInnes, L., Healy, J. & Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *ArXiv Preprint ArXiv:1802.03426*.
<https://doi.org/10.48550/arXiv.1802.03426>
27. Müllner, D. (2013). fastcluster: Fast hierarchical, agglomerative clustering routines for R and Python. *Journal of Statistical Software*, 53, 1–18.
28. Ollen-Bittle, N., Pejhan, S., Pasternak, S. H., Keene, C. D., Zhang, Q. & Whitehead, S. N. (2024). Co-registration of MALDI-MSI and histology demonstrates gangliosides co-localize with amyloid beta plaques in Alzheimer’s disease. *Acta Neuropathologica*, 147(1), 105. <https://doi.org/10.18637/jss.v053.i09>
29. Parees, D. M., Hanton, S. D., Clark, P. A. C. & Willcox, D. A. (1998). Comparison of mass spectrometric techniques for generating molecular weight information on a class of ethoxylated oligomers. *Journal of the American Society for Mass Spectrometry*, 9(4), 282–291. [https://doi.org/10.1016/S1044-0305\(97\)00291-2](https://doi.org/10.1016/S1044-0305(97)00291-2)
30. Pathirage, K., Virmani, A., Scott, A. J., Traub, R. J., Ernst, R. K., Ghodssi, R., Babadi, B. & Abshire, P. A. (2024). Interpretable dimensionality reduction and classification of mass spectrometry imaging data in a visceral pain model via non-negative matrix factorization. *Plos One*, 19(10), e0300526.
<https://doi.org/10.1371/journal.pone.0300526>
31. R Core Team, R. & others. (2013). *R: A language and environment for statistical computing*.
32. Ràfols, P., Torres, S., Ramàirez, N., Del Castillo, E., Yanes, O., Brezmes, J. & Correig, X. (2017). rMSI: an R package for MS imaging data handling and visualization. *Bioinformatics*, 33(15), 2427–2428.
<https://doi.org/10.1093/bioinformatics/btx182FulltextlinksCite>
33. Ren, J.-L., Zhang, A.-H., Kong, L. & Wang, X.-J. (2018). Advances in mass spectrometry-based metabolomics for investigation of metabolites. *RSC Advances*, 8(40), 22335–22350. <https://doi.org/10.1039/C8RA01574K>
34. Seydoux, C., Bryan, M., Barnes, J.-P. & Jouneau, P.-H. (2025). *Efficient denoising of mass spectrometry images by PCA-assisted self-supervised deep learning*.
35. Smets, T., Verbeeck, N., Claesen, M., Asperger, A., Griffioen, G., Tousseyn, T., Waelput, W., Waelkens, E. & De Moor, B. (2019). Evaluation of distance metrics and spatial autocorrelation in uniform manifold approximation and projection applied to mass spectrometry imaging data. *Analytical Chemistry*, 91(9), 5706–5714.
<https://doi.org/10.1021/acs.analchem.8b05827>
36. Smets, T., Waelkens, E. & De Moor, B. (2020). Prioritization of m/z-values in mass spectrometry imaging profiles obtained using uniform manifold approximation and projection for dimensionality reduction. *Analytical Chemistry*, 92(7), 5240–5248.
<https://doi.org/10.1021/acs.analchem.9b05764>
37. Tobias, F. & Hummon, A. B. (2020). Considerations for MALDI-based quantitative mass spectrometry imaging studies. *Journal of Proteome Research*, 19(9), 3620–3630. <https://doi.org/10.1021/acs.jproteome.0c00443>
38. Tressler, C., Tilley, S., Yang, E., Donohue, C., Barton, E., Creissen, A. & Glunde, K. (2021). Factorial design to optimize matrix spraying parameters for MALDI mass

- spectrometry imaging. *Journal of the American Society for Mass Spectrometry*, 32(12), 2728–2737. <https://doi.org/10.1021/jasms.1c00081>
39. Tuck, M., Grélard, F., Blanc, L. & Desbenoit, N. (2022). MALDI-MSI towards multimodal imaging: challenges and perspectives. *Frontiers in Chemistry*, 10, 904688. <https://doi.org/10.3389/fchem.2022.904688>.
 40. Van Der Maaten, L. (2014). Accelerating t-SNE using tree-based algorithms. *The Journal of Machine Learning Research*, 15(1), 3221–3245.
 41. Wallace, E. N., West, C. A., McDowell, C. T., Lu, X., Bruner, E., Mehta, A. S., Aoki-Kinoshita, K. F., Angel, P. M. & Drake, R. R. (2024). An N-glycome tissue atlas of 15 human normal and cancer tissue types determined by MALDI-imaging mass spectrometry. *Scientific Reports*, 14(1), 489. <https://doi.org/10.1038/s41598-023-50957-w>
 42. World Bladder Cancer Patient Coalition. (2022). *GLOBOCAN 2022: El cáncer de vejiga es el 9º más diagnosticado en el mundo*. Retrieved February 12, 2025, from <https://worldbladdercancer.org/es/novedades-eventos/globocan-2022-el-cancer-de-vejiga-es-el-9o-mas-diagnosticado-en-el-mundo/>
 43. Xu, G., Gan, S., Guo, B. & Yang, L. (2024). Application of clustering strategy for automatic segmentation of tissue regions in mass spectrometry imaging. *Rapid Communications in Mass Spectrometry*, 38(8), e9717. <https://doi.org/10.1002/rcm.9717>

ANEXO I: Tabla resumen de los métodos de reducción de la dimensionalidad aplicados en el estudio:

Para reducir la alta dimensionalidad de las matrices generadas tras la normalización, se aplicaron tres técnicas de reducción comúnmente utilizadas en estudios de espectrometría de masas por imágenes (MSI): PCA, t-SNE y UMAP. Estas herramientas permiten transformar los 1,874 valores de m/z por píxel a un número mucho menor de componentes, lo que facilita tanto la visualización como el análisis mediante algoritmos de clusterización. La siguiente tabla resume las características clave de cada método, incluyendo su tipo de reducción, número de componentes seleccionadas y el paquete de R empleado:

Reducción	Tipo reducción	Objetivo	Componentes seleccionadas	Matrices reducidas	Paquete de R utilizado
PCA	Lineal	Reducir la dimensionalidad preservando un % de varianza acumulada alto.	4 componentes y 100 componentes	pks, TIC, RMS y MAX.	FactoMiner(Lê et al., 2008)
t-SNE	No lineal	Preservar la estructura local de los datos.	2 componentes y 3 componentes	pks, TIC, RMS y MAX	Rtsne(Van Der Maaten, 2014)
UMAP	No lineal	Preservar la estructura global y local de los datos.	3 componentes	Pks, TIC, RMS y MAX	uwot(McInnes et al., 2018)

Tabla 1: Resumen de las técnicas de reducción de dimensionalidad aplicadas a las matrices de datos. Se detalla el tipo de reducción, los objetivos principales de cada técnica, las componentes seleccionadas, las matrices analizadas y los paquetes de R utilizados para cada proceso.

ANEXO II: Tabla resumen de los algoritmos de clusterización aplicados en el estudio:

Para identificar agrupamientos moleculares relevantes que reflejen las diferencias biológicas entre la región tumoral y la estromática, se aplicaron tres métodos de clusterización no supervisada ampliamente utilizados en estudios de espectrometría de masas por imágenes (MSI): K-Means, DBSCAN y HClust. Estos algoritmos agrupan los píxeles según sus características moleculares, permitiendo detectar patrones que podrían ser indicativos de la heterogeneidad del tejido. La siguiente tabla resume las características clave de cada algoritmo, incluyendo su tipo de agrupamiento, los parámetros utilizados y el paquete de R empleado:

Algoritmo	Tipo	Parámetros principales	Determinación número clústeres	Paquete de R utilizado
K-Means	No jerárquico	Número de clústeres	ELBOW + Validación visual	Base R(R Core Team & others, 2013)
DBSCAN	Basado en densidad	eps(radio), minPts(mínimo de puntos para ser un clúster)	No requiere número de clústeres explícito	dbscan(Hahsler et al., 2019)
HClust	jerárquico	Número de clústeres	Validación visual	Fastcluster(Müllner, 2013)

Tabla 2: Resumen de las técnicas de clusterización aplicadas. Se detalla el tipo de algoritmo, los parámetros principales de cada técnica, la determinación del número de clústeres empleada y los paquetes de R utilizados.

